UADER FCyT

Sistema de Test Vocacional Utilizando una Red Neuronal

Inteligencia Artificial

Profesores: Daniela López De Luise

Alejandro Perez

Alumnos: Benedetti Valentino
Benedetti Agustín
Frachia Franco
Nievas Juan
Saenz Juan

Grupo: Grupo 6

Año lectivo: 2026

1. ¿Cuál es el problema y cómo lo resolvemos?

La orientación vocacional de los estudiantes de secundaria suele ser un proceso complejo, costoso y, en muchos casos, inexistente por falta de recursos en las instituciones. Los tests tradicionales en papel requieren de una corrección manual y rígida que muchas veces no logra ramificar o crear nuevos perfiles de forma dinámica cuando los intereses de las nuevas generaciones cambian o surgen nuevas carreras en el mercado tecnológico y laboral.

Red Neuronal (ART1): En lugar de estructurar un sistema clásico de reglas duras e inflexibles, se opta por un enfoque conexionista utilizando el modelo ART1 de Carpenter y Grossberg.

- **Solución al dilema de estabilidad-plasticidad**: Es la ventaja principal de las redes ART. La red es plástica para aprender nuevas carreras o perfiles sin necesidad de ser reentrenada desde cero, pero es estable porque no olvida ni distorsiona las categorías de carreras que ya aprendió previamente.
- **Aprendizaje incremental y en tiempo real**: A medida que nuevos estudiantes con combinaciones de intereses únicas utilicen la plataforma, el sistema podrá crear categorías de manera totalmente automática si el perfil no encaja en las existentes.

2. Los datos que usamos y cómo los preparamos

Definición del Set de Datos:
Se aplicará una transformación por codificación dispersa sobre la escala discreta [1, 10] de cada variable. Cada una de las 11 características originales del dataset psicométrico RIASEC y de aptitudes se expandirá en 10 variables binarias con prefijo identificatorio (ej. Math_v1, Math_v2, ..., Math_v10).

De esta forma, el vector de entrada X para la capa F1 de la red ART-1 constará de un espacio dimensional de exactamente 110 bits (11 variables x 10 bines), donde cada variable original mantendrá exactamente un bit activo ('1') en el bin correspondiente a su puntaje original, y '0' en los nueve restantes.

Variables Originales a Binarizar (110 bits en total):
- Math_Score (v1 a v10). Afinidad por el cálculo y razonamiento numérico.
- Science_Score (v1 a v10). Interés en ciencias naturales y método científico.
- Programming_Skill (v1 a v10). Destreza lógica y computacional.
- Communication_Skill (v1 a v10). Capacidad de oratoria y relaciones humanas.
- Logical_Ability (v1 a v10). Resolución de problemas abstractos.
- R_score (v1 a v10). Perfil Realista (Práctico / Manejo de herramientas).
- I_score (v1 a v10). Perfil Investigador (Analítico / Científico).
- A_score (v1 a v10). Perfil Artístico (Creativo / Expresivo).
- S_score (v1 a v10). Perfil Social (Vocación de servicio / Cooperación).
- E_score (v1 a v10). Perfil Emprendedor (Liderazgo / Iniciativa comercial).
- C_score (v1 a v10). Perfil Convencional (Organización / Estructura de datos).

Origen y Volumen:
Para cumplir con las condiciones de entrega, el volumen total de datos extraído de Kaggle se dividirá en 2 datasets de uso independientes (dataset_A y dataset_B), cada uno con un mínimo de 55 registros y las 11 variables.

Limpieza y Preprocesamiento de Datos:

1. Escalamiento Previo: Las variables de rendimiento académico internacional (escaladas de 1 a 100) se normalizarán dividiéndolas por un factor de 10 para mapearlas al rango [1, 10].

2. Mapeo a Bines: Se asignará cada valor al bin discreto correspondiente [0,1), [1,2), ..., [9,10] activando la variable binaria unívoca correspondiente (vi = 1).

3. Volumen de Prueba: Se mantendrá la estructura de 2 datasets independientes (dataset_A.csv y dataset_B.csv) de más de 50 registros cada uno.

Filtrado de vectores nulos: Se eliminarán del set los vectores resultantes que queden completamente vacíos de intereses. Un vector nulo anula la estimulación matemática en la capa de comparación F1, impidiendo que el mecanismo de control de la red ART-1 procese la señal y active el reconocimiento de categorías.

3. ¿Cómo medimos si funciona bien?

Al tratarse de un modelo de aprendizaje no supervisado enfocado en el agrupamiento (clustering) , no podemos usar métricas tradicionales de error. En su lugar, evaluaremos el rendimiento mediante dos vías:

Métrica Técnica (Hiperparámetro de Vigilancia p): Medición del impacto del parámetro (p E [0,1]) en el agrupamiento (clustering). Se busca calibrar el punto óptimo para evitar la sub-clasificación (mezclar perfiles opuestos si p es muy bajo) y la sobre-clasificación (crear categorías excesivas si p es muy alto).

Métrica de Validación Externa (Coherencia Psicopedagógica): Se evaluará la consistencia teórica de las categorías formadas contrastando los patrones de los ejemplares (vectores de prototipo Top-Down) contra matrices teóricas de perfilado vocacional diseñadas por especialistas en psicopedagogía (verificando que clústeres con altos bines en lógica y programación asocien perfiles afines a ciencias exactas y tecnología).

4. Integrantes del equipo y Roles (Grupo 6)

Nievas Juan Jose (Líder / Documentación): Coordina las entregas del equipo y se encarga de redactar el informe, justificando teóricamente el comportamiento del modelo de Carpenter y Grossberg.

Benedetti Valentino (Responsable de Arquitectura): Diseña la estructura interna de la red ART1, definiendo el tamaño del vector de entrada, la capa de entrada (F1), la capa de salida (F2) y la lógica del mecanismo de control de ganancia y reinicio (Reset).

Benedetti Agustín (Responsable del Repositorio): Configura y mantiene el repositorio de Git, garantizando que el entorno de Python sea reproducible y resguardando los vectores de perfiles de prueba.

Saenz Juan Ignacio (Responsable del Código): Programa el algoritmo de ART1 en Python (la fase de comparación, la fase de búsqueda por resonancia y la actualización de los vectores de peso Bottom-Up y Top-Down).

Frachia Franco (Responsable del Test): Realiza las pruebas experimentales modificando el parámetro de vigilancia p para verificar cuántas categorías estables genera la red y mide la precisión contra los casos de prueba.

5. Documentación Preliminar (Marco Teórico)

La arquitectura elegida es una red ART1 (Teoria de Resonancia Adaptativa), un modelo conexionista diseñado específicamente para procesar datos binarios (ceros y unos) mediante aprendizaje no supervisado. Su estructura interna se compone de tres elementos clave que interactúan entre sí:

Capa de Comparación (F1): Es la puerta de entrada de la red. Recibe el perfil de intereses del alumno (el vector de 0 y 1) y se encarga de contrastarlo contra las carreras que la red ya conoce.

Capa de Reconocimiento (F2): Es la capa donde se almacenan las categorías o "perfiles de carreras" (ej: Emprendedor, contador, maestro, ingeniero software, doctor o científico de datos). Cada neurona en esta capa representa una carrera distinta. Sus conexiones con la capa F1 guardan los rasgos típicos de esa profesión.

Mecanismo de Reinicio (Reset) y Parámetro de Vigilancia (p): Es el "juez" o evaluador del sistema. Compara matemáticamente qué tan parecido es el alumno a la carrera sugerida.

- Si la similitud supera el parámetro de vigilancia (p), se genera resonancia (coincidencia) y se le asigna esa carrera.
- Si el alumno es muy diferente a todo lo conocido, el Reset desactiva esa opción y obliga a la red a crear una carrera nueva en la capa F2, logrando así el aprendizaje incremental sin borrar lo anterior.

Estructura Planificada del Repositorio (Git):

- **/data:** Contiene los perfiles de prueba binarizados (archivos JSON o CSV).

- **/src:** Código fuente en Python con la clase ART1 programada con lógica de matrices.
- **/notebooks:** Simulaciones experimentales de calibración del parámetro ρ.

Dataset:
https://www.kaggle.com/datasets/svenkateshkumar/student-career-prediction-using-riasec-dataset?resource=download