1. El preprocesamiento columna por columna: Rangos y Bines

Para construir el vector binario de 110 bits (11 variables x 10 bines), la teoría de Carpenter-Grossberg exige que cada una de las 11 variables se represente por un vector de 10 posiciones donde solo una de ellas sea 1 y el resto sean 0.

En nuestro dataset, las columnas se comportan de tres maneras distintas:

- **Rendimiento Académico (Math_Score y Science_Score):**
  - Rango original: Van de **60.0** a **97.0**.
  - Nuestra propuesta: Dividirlas por 10 para mapearlas al rango [6.0, 9.7]. Esto hace que un estudiante con un Math_Score de **88** se convierta en **8.8**.
  - Mapeo a Bines: Al usar intervalos semiabiertos \([0,1), [1,2), ...,\), el valor **8.8** cae exactamente en el **Bin 9** (que corresponde al índice 8 del vector, activando la posición Math_v9 en 1 y dejando el resto de Math_v1 a Math_v10 en 0).
- **Habilidades de Autoevaluación (Programming_Skill, Communication_Skill y Logical_Ability):**
  - Rango original: Estas columnas tienen un rango estricto de **2.0 a 5.0**.
  - Si aplicamos la lógica directa a bines sin reescalar, un valor de **3** activará el Bin 4 (v4), y un valor de **5** activará el Bin 6 (v6). Esto significa que **los bines del 1 al 2, y del 7 al 10 para estas tres variables siempre van a estar en 0** para todos los estudiantes en el dataset.
  - Como estas habilidades originalmente están medidas en una escala de 1 a 5, para aprovechar mejor los 10 bines de la red y aumentar la dispersión, las vamos a normalizar **multiplicándolas por 2**. Así, un Programming_Skill de 3 pasaría a ser 6 (Bin 7), y un 5 pasaría a ser 10 (Bin 10), utilizando todo el espectro de la capa F1.
- **Perfiles de Interés RIASEC (R_score, I_score, A_score, S_score, E_score, C_score):**
  - Rango original: Van de **0.0 a 10.0** (o de 0.0 a 8.0 en perfiles como el Artístico y Realista).
  - Mapeo a Bines: Al ser variables que ya están en la escala exacta de 0 a 10, no necesitan ninguna división ni multiplicación previa. Se binarizan directamente asignando su valor al bin correspondiente. (Por ejemplo, un interés de **0** activa el Bin 1 y un interés de **10** activa el Bin 10).

2. Demostración práctica: Cómo se binariza una fila real

Tomando el primer registro del archivo career_data.csv:

- Datos originales: Math_Score = 88, Science_Score = 90, Programming_Skill = 3, Communication_Skill = 4, Logical_Ability = 2, R_score = 5, I_score = 3, A_score = 5, S_score = 3, E_score = 9, C_score = 2.

Tras aplicar el escalamiento previo y mapear a bines del 0 al 9 (índices de Python):

1. Math_Score (8.8) se mapea a **Bin 9** (un 1 en la novena posición de su bloque)

2. Science_Score (9.0) se mapea a **Bin 10** (un 1 en la décima posición de su bloque)
3. Programming_Skill (3) se mapea a **Bin 6**
4. Communication_Skill (4) se mapea a **Bin 8**
5. Logical_Ability (2) se mapea a **Bin 4**
6. R_score (5) se mapea a **Bin 6**
7. I_score (3) se mapea a **Bin 4**
8. A_score (5) se mapea a **Bin 6**
9. S_score (3) se mapea a **Bin 4**
10. E_score (9) se mapea a **Bin 10**
11. C_score (2) se mapea a **Bin 3**

Esto genera un vector de exactamente 110 bits que contiene **exactamente 11 unos** y **99 ceros**.

3. Garantía matemática: Cero vectores nulos

Dado que cada una de las 11 variables de cada estudiante siempre tiene un valor asignado (sin filas vacías en el CSV), la codificación dispersa asegura que cada vector binario de entrada X tendrá siempre una norma exactamente igual a 11. Nunca habrá un vector con todo ceros.

4. La columna Career

Como la red ART1 realiza **aprendizaje no supervisado**; agrupa a los estudiantes basándose estrictamente en la similitud estructural de sus intereses y habilidades, sin saber qué carrera quiere seguir cada uno.

Por lo tanto, al procesar el archivo CSV, vamos a **excluir la columna categórica Career del entrenamiento**. Sin embargo, esta columna es sumamente valiosa: cuando la red haya agrupado a los estudiantes en clústeres (por ejemplo, Clúster 0, Clúster 1, etc.), vamos a poder analizar qué carreras originales tenían los integrantes de cada clúster. Si vemos que los estudiantes del "Clúster 0" tienen en su gran mayoría la etiqueta original de "Software Engineer" o "Data Scientist", vamos a poder validar que la red funciona bien.

El preprocesamiento lo vamos a implementar en Python con pandas.